

Arquitectura para Inferencia Filogenética de SARS-CoV-2

Guillermo Gutiérrez Caracuel

18 de abril de 2026

Resumen

Este documento describe un pipeline automatizado de alto rendimiento para la inferencia filogenética de secuencias de SARS-CoV-2. Orquestado mediante *Snakemake*, el flujo de trabajo integra herramientas de bajo nivel en Rust para filtrado inicial, alineamiento paralelo con MAFFT, control de calidad matricial en Python (NumPy/Biopython) y construcción de árboles filogenéticos por Máxima Verosimilitud (*Maximum Likelihood*) usando IQ-TREE.

1. Introducción

El análisis filogenético a gran escala de secuencias virales requiere soluciones eficientes y completamente automatizadas. El objetivo principal de este proyecto es proporcionar una **arquitectura de automatización y alto rendimiento** capaz de procesar de manera masiva secuencias genómicas del virus SARS-CoV-2. Esto permite generar árboles filogenéticos robustos con una intervención manual mínima, garantizando la reproducibilidad técnica, la escalabilidad estructural y una gran eficiencia computacional.

2. Arquitectura del Sistema

Para asegurar la mantenibilidad y modularidad del software, el repositorio sigue una jerarquía de directorios bien definida que separa los datos crudos, el código fuente y los artefactos generados.

```
sars-cov-2-phylogeny/  
├─ bin/ ... Binarios precompilados (iqtree3, sars_filter, datasets)  
├─ data/ ... Almacenamiento de secuencias FASTA crudas y procesadas  
├─ doc/ ... Documentación académica y técnica  
├─ results/ ... Resultados finales (alineamientos, árboles y gráficos QC)  
├─ sars_filter/ ... Código fuente en Rust para el filtrado rápido  
├─ scripts/ ... Scripts de análisis vectorial en Python  
└─ Snakefile ... Grafo de ejecución del orquestador
```

3. Diseño del Grafo Acíclico Dirigido (DAG)

El flujo de ejecución está gobernado por **Snakemake** a través de un Grafo Acíclico Dirigido (DAG), el cual asegura que cada regla se ejecute únicamente cuando sus dependencias directas

e indirectas estén satisfechas.




Figura 1: Grafo Acíclico Dirigido (DAG) que ilustra las 5 fases secuenciales del pipeline.

4. Fundamentos Matemáticos e Implementación

4.1. Filtrado de Secuencias (Rust)

Para lidiar con el alto volumen de datos genómicos, el primer paso de limpieza se realiza empleando el binario `sars_filter` implementado en Rust. Este algoritmo nativo examina iterativamente cada secuencia del genoma viral con una **complejidad algorítmica de $\mathcal{O}(n)$** , siendo n el número de secuencias analizadas.

El filtro computacional asegura que la secuencia posea una longitud biológicamente plausible en un genoma libre de deleciones críticas, definida estrictamente en el intervalo:

$$L \in [29000, 30500] \text{ pares de bases} \quad (1)$$

4.2. Inferencia Filogenética (IQ-TREE)

La fase final reconstruye la historia evolutiva de las secuencias utilizando la metodología de **Máxima Verosimilitud** (*Maximum Likelihood*). Bajo este riguroso marco estadístico, IQ-TREE busca la topología del árbol T y los parámetros del modelo evolutivo θ que maximicen la probabilidad de observar el alineamiento de los datos reales D . La función de verosimilitud se define matemáticamente como:

$$\mathcal{L}(\theta, T) = P(D \mid \theta, T) \quad (2)$$

Para determinar de forma no sesgada el modelo evolutivo óptimo θ , se emplea internamente la herramienta ModelFinder, la cual evalúa distintos modelos de sustitución nucleotídica (ej. GTR+F+I) penalizando la sobreparametrización mediante el *Criterio de Información de Akaike* (AIC) o el *Criterio de Información Bayesiano* (BIC).

5. Reproducibilidad y Entorno de Ejecución

La portabilidad técnica y la consistencia del pipeline a través de diferentes máquinas (basadas en Linux x86_64) se logra mediante herramientas de aislamiento de software como `uv` y el suministro de archivos binarios estáticos. A continuación, se detallan los comandos necesarios para reproducir el entorno:

```
1 # 1. Sincronizar el entorno estricto de dependencias de Python
2 uv sync
3
4 # 2. Otorgar permisos de ejecucion a los binarios locales
5 chmod +x bin/sars_filter bin/iqtree3 bin/datasets
6
7 # 3. Lanzar la topologia DAG de Snakemake (ej: empleando 16 hilos)
8 uv run snakemake -c 16
```

Listing 1: Instrucciones de orquestación y arranque del pipeline

Una vez finalizado el subproceso automatizado, los ficheros resultantes (`.treefile` en formato Newick y los gráficos de calidad poblacional en `.pdf`) quedarán localizados en el directorio `results/`.